

基于自监督学习的去流行度偏差推荐方法

张 帅^{1,2}, 高 旻^{1,2}, 文俊浩^{1,2}, 熊庆宇^{1,2}, 唐 旭²

(1. 信息物理社会可信服务计算教育部重点实验室(重庆大学), 重庆 400044; 2. 重庆大学大数据与软件学院, 重庆 400044)

摘 要: 近年来,随着推荐系统研究的不断深入,推荐系统的公平性受到越来越多关注. 流行度偏差也即流行的物品比非流行的物品更容易被推荐,是影响其公平性的重要因素之一. 流行度偏差对推荐系统的各利益相关者都有严重的影响,引起研究者的广泛关注. 相关研究主要通过推荐结果重排或学习过程中融合正则化项提升非流行物品的曝光率,而非流行物品的交互数据极度稀疏成为研究的瓶颈. 针对此问题,本文提出基于自监督学习的去流行度偏差推荐方法,解决两个难点:(1)准确学习交互数据极度稀疏的非流行物品的表征;(2)提升非流行物品曝光率的同时,兼顾不同用户对流行和非流行物品的偏好. 具体地,从用户的角度,提出流行物品和非流行物品双视图的用户偏好学习方法,准确学习用户对流行和非流行物品的真实偏好;从物品的角度,采用自监督学习,利用互信息最大化捕获非流行物品与流行物品间的潜在关系,辅助提升非流行物品嵌入学习的准确性. 最后,设计用户流行度偏好一致性、资格公平性等指标,并通过三个公开数据集的大量实验说明了本文方法在提升推荐性能的同时,能有效缓解流行度偏差问题并具有较强的通用性.

关键词: 推荐系统; 协同过滤; 公平性; 流行度偏差; 自监督学习

中图分类号: TP311

文献标识码: A

文章编号: 0372-2112(2022)10-2361-11

电子学报 URL: <http://www.ejournal.org.cn>

DOI: 10.12263/DZXB.20210443

Self-Supervised Learning for Alleviating Popularity Bias in Recommender Systems

ZHANG Shuai^{1,2}, GAO Min^{1,2}, WEN Jun-hao^{1,2}, XIONG Qing-yu^{1,2}, TANG Xu²

(1. Key Laboratory of Dependable Service Computing in Cyber Physical Society (Chongqing University),
Ministry of Education, Chongqing 400044, China;

2. School of Big Data & Software Engineering, Chongqing University, Chongqing 400044, China)

Abstract: In recent years, with the development of recommender system, more and more attention has been paid to the fairness of recommender system. Popularity bias means that popular items are more likely to be recommended than unpopular items, which is one of the important factors affecting its fairness. Popularity bias has a serious impact on all stakeholders in the recommendation system, which has aroused widespread concern of researchers. Related research mainly improves the exposure rate of unpopular items by the rearrangement of recommended results or the integration of regularization items in the learning process, but the extremely sparse interaction data of unpopular items becomes the bottleneck of research. To solve this problem, this paper proposes self-supervised learning for alleviating popularity bias (SSLAB) to deal with two difficulties: (1) accurately learning the representation of unpopular items with extremely sparse interactive data; (2) improving the exposure rate of unpopular items while taking into account the preferences of different users for popular and unpopular items. Specifically, from the perspective of users, this paper proposes a dual view user preference learning method for popular and unpopular items to accurately learn users' real preferences for popular and unpopular items; from the perspective of items, self-supervised learning is used to capture the potential relationship between unpopular items and popular items by maximizing mutual information to help improve the accuracy of unpopular items embedded learning. Finally, metrics such as user popularity preference consistency and qualification fairness are designed, and a large number of

收稿日期: 2021-04-07; 修回日期: 2021-09-02; 责任编辑: 王天慧

基金项目: 国家自然科学基金(No.72161005); 重庆市自然科学基金(No.cstc2020jcyj-msxmX0690); 重庆大学中央高校基本科研业务费项目(No.2020CDJ-LHZZ-039); 重庆市技术创新与应用发展专项重点项目(No.cstc2019jsx-fxydX0012); 重庆市留学人员创业创新支持计划(No.cx2020097)

experiments on three open data sets show that the proposed method can effectively alleviate the popularity bias and has a strong scalability while improving the recommendation performance.

Key words: recommender system; collaborative filtering; fairness; popularity bias; self-supervised learning

1 引言

近年来,推荐系统被广泛应用于电商平台和社交媒体等场景.作为推荐系统重要基础的协同过滤根据共同群体偏好实现个性化推荐,其输入数据的不平衡和损失函数的不公平,使其容易遭受流行度偏差问题^[1],即相较于非流行的物品(亦称为长尾物品),系统更倾向于推荐流行的物品.这导致了系统中的马太效应:流行物品被曝光给用户的频率会越来越多,而非流行物品被推荐的频率则越来越少.

推荐系统有多种利益相关者,例如在电商场景,有提供物品的商家、作为消费者的用户和推荐平台等利益相关者,如图1所示.为了减少流行度偏差的影响,有研究者从保障物品公平性的角度,针对非流行物品的曝光率,进行了相关研究.如Vargas等人^[2]调换用户和物品的角色,通过向物品推荐用户,增加了推荐列表的整体多样性;Abdollahpouri等人^[3,4]则从推荐列表中筛选曝光率低但相关性高的物品,生成非流行物品比例更高的新推荐列表;还有研究在训练过程中引入公平性约束,使得推荐列表中的物品尽可能不相似^[5].然而,现有研究没有从用户和物品两个方面考虑流行度偏差问题.由于不同用户对非流行物品的偏好程度并不一致,所以不加区分地提高所有用户推荐列表中的非流行物品比例将影响用户体验.因此,本文基于从用户和物品两个角度的综合分析,提出基于自监督学习的去流行度偏差推荐方法(Self-Supervised Learning for Alleviating popularity Bias, SSLAB).该方法在提高非流行物品曝光率的同时,兼顾用户对流行物品和非流行物品的偏好程度,既缓解流行度偏差问题也考虑用户体验.实现这个目标要解决两个重要问题:(1)如何降低流行度对用户真实兴趣的影响,学习到用户对流行物品和非流行物品的个性化偏好,即提升非流行物品曝光率的同时,兼顾不同用户对流行和非流行物品的偏好?(2)用户与非流行物品的交互很少,如何准确学习交互数据极度稀疏的非流行物品的表征?

为应对问题(1),SSLAB采用双视图用户偏好学习方法,对物品按流行度划分为流行与不流行两个视图,并在两种视图下分别计算用户偏好,从而避免了在捕获用户真实兴趣时,物品流行度的干扰.针对问题(2),为了缓解非流行物品数据稀疏问题,采用自监督学习,通过最大化流行物品视图与非流行物品视图间的互信息,捕获非流行物品与流行物品间潜在的联系,辅助非流行物品表征的学习.基于上述设计,SSLAB将推荐任




图1 推荐系统的各利益相关者(电商场景)

务和自监督学习任务整合,兼顾推荐系统性能和非流行物品个性化偏好的同时,缓解流行度偏差问题.本文主要贡献如下:

(1)从数据分布、评价指标、优化方法、推荐平均长尾物品占比等多个方面,深入分析了推荐系统流行度偏差现象及原因;

(2)首次将自监督学习用于缓解流行度偏差,提出双视图用户兴趣学习方法,设计包含流行/非流行物品掩码、基于自注意力的隐式表征关键信息提取、双视图互信息最大化的辅助任务,形成基于自监督学习的去流行度偏差推荐方法(SSLAB);

(3)设计了用户和物品公平性的评价指标,如用户流行度偏好一致性、机会公平性和资格公平性等,并以图神经网络模型LightGCN^[6]和NGCF^[7]等为基本模型,在公开数据集上进行大量实验验证了SSLAB缓解流行度偏差上的有效性和可扩展性.

2 相关工作

本节首先介绍推荐系统隐因子模型,然后概述自监督学习,最后介绍影响推荐系统公平性重要因素:流行度偏差.

2.1 隐因子模型(Latent Factors Model)

目前多数推荐算法都采用隐因子模型^[6-9].该模型将用户和物品映射到同一低维隐式空间,通过用户与物品的隐式表征作内积得到用户对物品的评分或者产生交互的概率.

隐因子模型的优化方法中,贝叶斯个性化排序(Bayesian Personalized Ranking, BPR)^[10]是常用的一种. BPR主要假设:相较于未交互的物品,用户更喜欢已产生交互的物品.其根据用户-物品隐反馈矩阵为每个用户构建偏好矩阵.基于偏好矩阵,建立三元组 (u, i, j) 数据集 D_s ,即

$$D_s := \{(u, i, j) | i \in I_u^+ \cap j \in I/I_u^+\} \quad (1)$$

其中, I_u^+ 和 I/I_u^+ 分别表示用户 u 已经产生正反馈的物品集合和未产生正反馈的物品集合.

BPR 优化目标可以表示为

$$\arg \min_{X, Y} \sum_{(u, i, j) \in D_s} -\ln \sigma(\hat{R}_{ui} - \hat{R}_{uj}) + \lambda (\|X\|^2 + \|Y\|^2) \quad (2)$$

其中, \hat{R}_{ui} 和 \hat{R}_{uj} 分别为用户 u 对物品 i 和 j 的偏好程度; X 和 Y 分别为用户和物品的隐式表征矩阵; $\sigma(\cdot)$ 为非线性激活函数; λ 为正则化系数.

2.2 自监督学习

自监督学习^[11]是一种新兴的机器学习范式. 通过自监督学习, 模型可以更充分地利用相关信息以辅助主任务. 互信息最大化^[11-13]是自监督学习的一个分支. 它受 InfoMax 原理^[13]的启发, 在计算机视觉^[11]、音频处理^[14]和自然语言理解^[12]等领域取得了重要进展. 这种方法将输入数据分割成多个视图, 并最大化这些视图表示之间的互信息.

目前已经有自监督学习与推荐系统结合的工作, 例如, Zhou 等人^[15]将上下文信息中的相关性作为序列推荐中的自监督信号, 最大化属性、项目和序列视图之间的互信息. Ma 等人^[16]则最大化不同时间序列物品间的互信息. 与上述方法不同, 本文将自监督学习用于缓解推荐系统的流行度偏差问题, 通过最大化流行物品视图与非流行物品视图间的互信息, 学习更完备的物品隐式表征.

2.3 流行度偏差

流行度偏差是影响推荐系统公平性的主要因素之一, 特别是主流的基于协同过滤的推荐算法^[17]. 流行度偏差使得大部分非流行物品被忽略, 导致推荐结果并不一定符合用户偏好^[18]. 然而, 流行的物品很可能被用户熟知, 推荐非流行物品对用户而言才更有意义, 而且还可以避免流行物品对市场的垄断, 增加推荐的惊喜性和新颖性.

有研究者提出了控制流行度偏差的方法, 增加非流行物品被曝光的机会, 如 Patro 等人^[19]考虑了用户的满意度和非流行物品的曝光率, 重排推荐结果权衡双方的利益. 但这类方法通常高度依赖初始推荐结果的质量, 所得的结果往往是次优的.

为缓解这些问题, 有研究者将公平性融入学习过程, 直接为用户推荐最优排序, 如 Himan 等人^[5]提出一个正则化项权衡准确率和公平性. 也有研究者使用逆倾向分数对损失函数进行加权, 使得用户更可能点击的物品在训练中的权重降低^[20, 21].

尽管流行度偏差是针对物品方公平性而言的, 但上述算法中的大多只以提高非流行物品曝光率为目标, 或者只将准确率等指标作为用户满意度, 忽略了用

户方对于流行物品的偏好程度.

3 问题分析

流行度偏差的出现, 除了数据自身的偏差等内部原因, 还包括评价指标和优化方法等外部原因. 为了深入分析流行度偏差出现的原因, 本节首先分析了数据集集中的偏差现象以及性能评价指标的不完善, 然后分析了经典 BPR 优化方法在公平性方面的不足, 并通过实验分析说明流行度偏差问题.

3.1 数据集中的偏差现象

设物品的流行度为其被用户评分的次数, 从 LastFM 数据集的物品流行度分布情况可以看出其呈现出明显的长尾分布, 如图 2 所示. 在其他数据集中也有类似的分布. 根据文献^[18], 本文将流行度前 20% 的物品定义为流行物品, 如图 2 虚线左边的部分, 其余的为非流行物品.




图2 LastFM 数据集物品流行度分布

统计结果表明, 在 LastFM 数据集中流行物品的评分占比为 78.3%. 所以, 推荐系统中数据本身往往就存在严重的流行度偏差现象.

3.2 评价指标的不完善

推荐系统最常用的评价指标为准确率、召回率等, 这些指标偏向于用户方面, 忽略了物品方的曝光率等因素. 只追求较高的准确率间接地加剧了物品方流行度偏差现象.

具体来说, 由于流行的物品占据了绝大部分的评分, 所以流行的物品出现在测试集的概率远远高于非流行物品. 这与分类算法中的类别极度不平衡的情况相似, 将所有结果都预测为样本量多的类, 就可以得到较好的准确率. 同理, 推荐算法的优异性能往往是基于频繁地推荐流行物品的, 所以大部分推荐算法不可避免地存在流行度偏差问题.

3.3 BPR 的公平性问题分析

经典的 BPR 方法虽然在推荐准确性上有较好的表

现,但却存在公平性问题:从其损失函数(如式(2))可以看出,BPR只粗略地让用户对正反馈的物品交互的概率大于对负样本的交互概率.由于非流行物品数量多,在负采样时被采样为负样本的概率大,因此模型就学习到用户对流行物品的交互概率大于对非流行物品的点击概率,一方面导致结果中流行物品的比例过高,另一方面放大了用户对流行物品的偏好程度,无法学习到用户真实的兴趣.

3.4 BPR的流行度偏差现象

图3对比了基于流行度的算法(Most Popular, MP)和基于BPR的经典算法(Matrix Factorization-Bayesian Personalized Ranking, MF-BPR)在Douban数据集上的表现:基于流行度的推荐算法也可以得到与BPR算法性能相近的推荐结果.




图3 Douban数据集中的准确率对比

进一步地,图4展示了Most Popular、MF-BPR和LightGCN-BPR三种算法的推荐结果中平均长尾物品占比(Average Percentage of Long Tail items, APLT)与用户交互历史中平均长尾物品占比的对比,用于反映流行度偏差的程度.原始数据中,APLT为15.5%,而在top10时,MF-BPR和LightGCN-BPR中APLT分别被缩小到0.4%和1.5%,接近于MP的结果0%,反映了BPR存在严重的流行度偏差问题.




图4 Douban数据集中的APLT对比

4 方法

为了缓解上述问题,本文提出一种基于自监督学习的去流行度偏差推荐方法(SSLAB). SSLAB主要分为两部分,如图5所示.

一部分是主任务部分,从用户交互历史中学习用户和物品的隐式表征.本文提出双视图用户兴趣学习方法,将物品按流行度划分在不同视图,并在流行物品和非流行物品两种不同视图下分别学习用户的兴趣,从而避免了捕获用户真实兴趣时,流行物品对非流行物品的干扰.

另一部分为辅助任务部分,从物品角度增强非流行物品表征的学习过程.本文通过最大化两个视图的互信息,构建自监督优化目标,缓解非流行物品数据稀疏的问题.

本节首先介绍方法涉及的主要概念定义,然后说明SSLAB的两个主要部分以及目标函数.

4.1 概念定义

定义1 物品流行度:物品*i*的交互(点击或购买)次数被称为该物品的流行度.

定义2 流行物品与非流行物品:设置一个流行度阈值,若物品流行度大于该阈值,则被称为流行物品;否则为非流行物品.

4.2 主任务部分

主任务部分采用隐因子模型从用户交互历史中学习用户和物品的隐式表征.隐因子模型可以使用主流的MF、LightGCN等模型.在缓解流行度偏差过程中,盲目地提升非流行物品的曝光率会牺牲用户体验.捕获用户的真实兴趣是十分必要的.

假设用户的交互行为来源于用户自身对物品的兴趣和物品的流行度,即用户点击或购买某一个物品并不是因为他对物品的兴趣 P_{int} ,还可能受到物品流行度 P_{pop} 的影响^[22,23].形式化表示如下:

$$P_{click} = P_{pop} + P_{int} \quad (3)$$

对于流行物品,尽管用户对它的兴趣并不高,即 P_{int} 可能很小,但非常高的 P_{pop} 导致流行物品被频繁地展示,进而提高了点击的概率.如果按照BPR的优化公式(式(2)),不区分 P_{pop} 和 P_{int} , P_{int} 将被 P_{pop} 干扰而难以学习到用户真实的兴趣.所以,学习用户兴趣偏好需要避免物品流行度的干扰.

因此,本方法采用双视图学习方式,首先将物品集*I*按照流行度划分为流行物品集 I^p 和非流行物品集 I^{np} 两部分,形成两个视图,然后对两个视图分别学习用户的真实兴趣.

具体地,对流行物品视图和非流行物品视图,分别构建BPR优化目标,然后综合两个目标,化简得到损失函数:

$$\begin{aligned}
L_1 = & - \sum_{(u,i,j) \in D_p} \log \sigma(\hat{R}_{ui} - \hat{R}_{uj}) \\
& - \sum_{(u,i,j) \in D_{up}} \log \sigma(\hat{R}_{ui} - \hat{R}_{uj}) \\
= & - \sum_{(u,i,j) \in D_p} \log \sigma(X_u^T Y_i - X_u^T Y_j) \\
& - \sum_{(u,i,j) \in D_{up}} \log \sigma(X_u^T Y_i - X_u^T Y_j) \\
& + \lambda (\|X\|^2 + \|Y\|^2)
\end{aligned} \quad (4)$$

其中, D_p 表示正样本 i 与负样本 j 均为流行物品的训练集; D_{up} 则表示正样本 i 与负样本 j 均为非流行物品的训练集; X_u 和 Y_i 分别表示用户 u 和物品 i 通过隐因子模型得到的隐式表征; λ 为正则化系数。

4.3 辅助任务部分

用户与非流行物品的交互记录十分稀疏,即有限的监督信号限制了非流行物品隐式表征的准确学习。自监督学习可以有效地解决这个问题,它利用内在的数据关联设计辅助训练目标,从有限的构建中构建自监督信号,通过最大化流行物品视图与非流行物品视图的互信息,更充分地学习物品的隐式表征,缓解非流行物品数据稀疏问题。具体地,通过掩码层将用户交互物品划分为流行物品视图和非流行物品视图;然后通过基于自注意力机制的特征提取层分别提取两个视图所包含的流行和非流行的物品信息;最后使用互信息最大化层最大化两个视图的互信息,捕获视图间的关联。自监督学习模型的结构如图5左半部分所示,主要分为三层:掩码层、特征提取层和互信息最大化层。

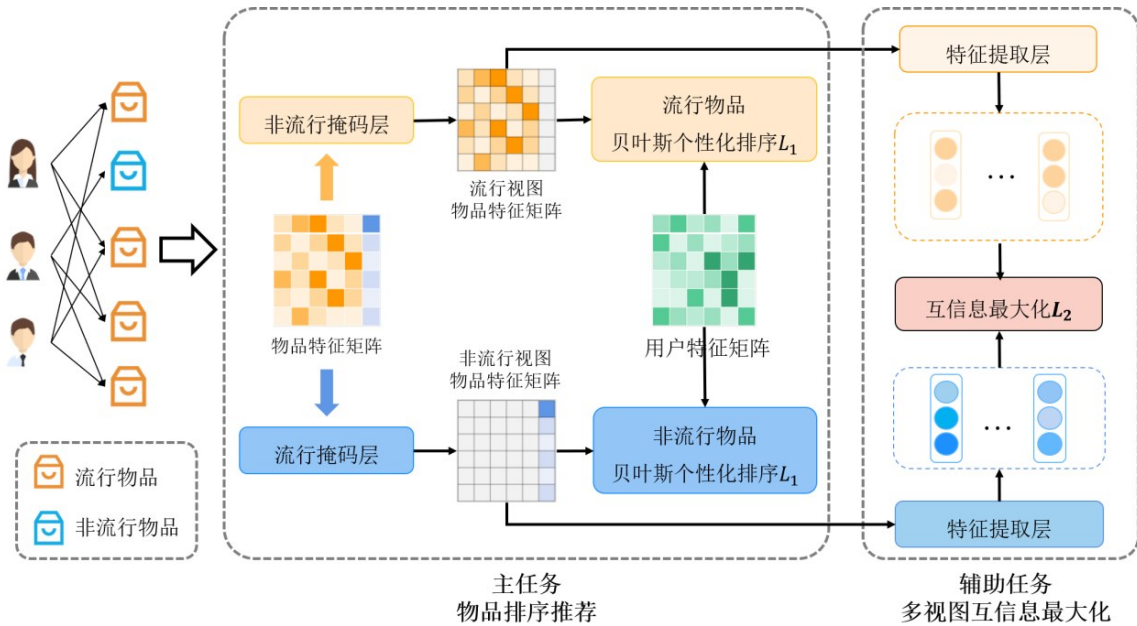


图5 基于自监督学习的去流行度偏差推荐方法

4.3.1 掩码层

类似于 Bert 模型^[24], 本文设计了一个掩码层分别屏蔽用户交互历史中的流行物品和非流行物品, 得到非流行物品视图和流行物品视图。设用户的交互历史为 $\{i_1^p, i_2^p, \dots, i_t^p, i_{t+1}^{up}, \dots, i_n^{up}\} \in \mathbf{I}$, 对应的隐式表征为 $\{Y_1^p, Y_2^p, \dots, Y_t^p, Y_{t+1}^{up}, \dots, Y_n^{up}\} \in \mathbf{R}^{1 \times D}$ 。其中, i_x^p 表示流行物品, 数量为 t ; i_x^{up} 表示非流行物品, 数量为 $n-t$, n 为用户交互历史中物品总数。分别对流行物品和非流行物品的隐式表征进行掩码操作, 得到流行物品视图的隐式表征为 $Y^p = \{Y_1^p, Y_2^p, \dots, Y_t^p, \text{mask}, \dots, \text{mask}\} \in \mathbf{R}^{n \times D}$, 非流行物品视图的隐式表征为 $Y^{up} = \{\text{mask}, \dots, \text{mask}, Y_{t+1}^{up}, \dots, Y_n^{up}\} \in \mathbf{R}^{n \times D}$ 。

4.3.2 特征提取层

掩码层得到的双视图下的物品隐式表征, 一方面作为推荐算法的输入, 另一方面输入到特征提取层。特征提取层负责从同一视图下物品隐式表征中提取关键信息。特征提取层的结构^[15,24,25]如图6所示, 主要由自注意力层、前馈层和残差层组成。

(1) 自注意力层。该层的输入为物品的隐式表征 $Y^x, x=p$ 或 up 。将 Y^x 经过三种线性变换分别得到:

$$\begin{aligned}
Q &= Y^x W^Q \\
K &= Y^x W^K \\
V &= Y^x W^V
\end{aligned} \quad (5)$$

其中, $W^Q \in \mathbf{R}^{D \times H}$, $W^K \in \mathbf{R}^{D \times H}$ 和 $W^V \in \mathbf{R}^{D \times H}$ 是三个维度为 $D \times H$ 的映射矩阵。采用点积计算注意力值:




图6 特征提取层

$$\text{Attention}(Q, K) = \text{softmax}\left(\frac{QK^T}{\sqrt{H}}\right) \quad (6)$$

其中, \sqrt{H} 为比例因子, 用于防止内积值过大. 自注意力层的输出为

$$O^{\text{att}} = \text{Attention}(Q, K) \cdot V \quad (7)$$

(2) 前馈层. 特征提取层使用一层全连接层作为前馈层. 为了防止过拟合, 在前馈层后加上一个 dropout 层, 所以前馈层最后的输出为

$$O^{\text{linear}} = \text{dropout}(O^{\text{att}}W^o + b^o) \quad (8)$$

其中, $W^o \in \mathbf{R}^{H \times D}$ 和 $b^o \in \mathbf{R}^{D \times 1}$ 分别为全连接层中待训练的权重矩阵和偏移量.

(3) 残差层. 为更好地保留物品原始隐式表征的信息, 特征提取层将原始隐式表征与前馈层的输出相加, 使输出向量中既包含单个物品的原始信息, 也包含了整个视图下物品的信息. 然后经过层归一化, 得到最终特征提取层的输出. 计算方式如下:

$$O^x = \text{LN}(O^{\text{linear}} + Y^x) \quad (9)$$

其中, $x=p$ 或 up ; $\text{LN}(\cdot)$ 表示层归一化.

4.3.3 互信息最大化层

在双视图学习中, 模型可以分别学习到流行物品和非流行物品的隐式表征. 这两种向量分别包含用户对流行物品和非流行物品的偏好. 作为同一用户的真实兴趣, 两种视角下的物品向量间存在关联性, 因此可以将这种关联性作为自监督信号: 如果两种物品向量属于同一用户的不同视图下, 则它们为正标签, 否则为负标签.

本文将流行物品视图与非流行视图视为同一用户偏好的不同角度, 通过二元交叉熵形式的 InfoNCE^[14] 进行对比学习, 最大化二者的互信息. 因此, 最大化互信息的损失函数为

$$L_2 = -\left[\log \sigma(f(O^p, O^{\text{up}})) + \log \sigma(1 - f(\tilde{O}^p, O^{\text{up}}))\right]$$

$$-\left[\log \sigma(f(O^p, O^{\text{up}})) + \log \sigma(1 - f(\tilde{O}^p, O^{\text{up}}))\right] \quad (10)$$

其中, 第一部分为在流行物品视图下选择负样本, 表示为 \tilde{O}^p ; 第二部分为在非流行视图下选择负样本, 表示为 \tilde{O}^{up} .

4.4 目标函数

SSLAB 将综合用户角度与物品角度, 在保障用户体验的同时, 缓解流行度偏差问题. 采用“主任务+辅助任务”形式, 联合训练模型的两个部分. 即融合式(4)和式(10), 得到损失函数如下:

$$L = L_1 + \alpha L_2 + \lambda \|\theta\|^2 \quad (11)$$

其中, α 为超参数, 控制辅助任务间的权重; λ 为正则化系数; θ 为模型的所有可训练参数, 如 X, Y, W^Q, W^K, W^V, W^O 等.

5 实验及分析

本节将在推荐系统常用数据集上验证 SSLAB 的有效性. 实验分为三个部分. 第一部分选择召回率、资格公平性等评价指标, 对比 SSLAB 与其他方法对流行度偏差和推荐相关性的影响. 第二部分为可扩展性实验, 将说明 SSLAB 优化方法在多种推荐模型上的表现, 以验证其具有可扩展性. 第三部分为参数敏感性分析实验, 阐述了超参数 α 对公平性与相关性之间的权衡. 实验主要回答三个问题:

问题1 SSLAB 与其他优化方法相比, 可以在推荐结果保持较高相关性的同时, 实现更好的物品公平性和用户体验吗?

问题2 在扩展性方面, SSLAB 对经典的 MF 模型以及 NGCF 和 LightGCN 等图卷积推荐模型的通用性如何?

问题3 用于调整主任务和辅助任务权重的超参数 α 的变化, 对 SSLAB 性能的影响如何?

5.1 实验设计

5.1.1 数据集及对比算法

本文使用 Douban, LastFM 和 Epinions 这 3 个公开数据集进行实验. 三个数据集都去除了反馈数少于 5 的用户, 去除后的数据集的统计数据如表 1 所示. 实验时随机抽取 80% 作为训练集, 10% 作为验证集, 剩余 10% 作为测试集.

实验包含 4 类对比算法: 3 种基础方法; 2 种后处理

表1 数据集统计

数据集	用户数	物品数	反馈数	稀疏度
Douban	2 562	30 679	441 935	99.44%
LastFM	1 867	17 487	73 698	99.77%
Epinions	40 163	139 736	664 824	99.99%

策略算法即 xQuAD^[5]和 FairRec^[19]; 2 种基于倾向分数的方法即 CMIPS^[20], CIPS^[21]; 1 种基于正则项的方法即 ESAM^[26].

5.1.2 用户方评价指标

本文采用的用户方评价指标,除了常规的召回率 (Recall) 和归一化折损累计增益 (NDCG), 还包括了用户流行度偏好一致性 (the change in the Group Average Popularity, ΔGAP)^[18] 和流行物品数量 (Number of Popular items, NP).

(1) 用户流行度偏好一致性: 不同的用户组推荐列表中物品平均流行度的变化. 当其大于 0 时, 说明推荐算法放大了流行度偏差. 计算方式如下:

$$\Delta GAP = \frac{GAP(g)_r - GAP(g)_p}{GAP(g)_p} \times 100\% \quad (12)$$

其中, $GAP(g)_p$ 和 $GAP(g)_r$ 分别表示用户交互历史的组平均流行度和用户推荐列表的组平均流行度, 即

$$GAP(g)_p = \frac{\sum_{i \in P_u} \varphi(i)}{\sum_{u \in g} |P_u|} \quad (13)$$

$$GAP(g)_r = \frac{\sum_{i \in R_u} \varphi(i)}{\sum_{u \in g} |R_u|} \quad (14)$$

其中, $\varphi(i)$ 表示物品 i 的流行度 (该物品被用户点击的次数); g 表示不同的用户组; P_u 表示用户 u 的交互记录; R_u 表示用户 u 的推荐列表.

(2) 流行物品数量: 在推荐列表中, 平均每个用户的流行物品数量. 计算方式如下:

$$NP@K = \frac{1}{|U|} \sum_{u \in U} |R_u@K \cap I^p| \quad (15)$$

5.1.3 物品方评价指标

(1) 机会公平性 (Opportunity Fairness, OF)^[4]: 衡量物品被曝光的机会大小. OF 用于度量非流行物品在推荐结果中的次数占比, 如式 (16) 所示:

$$OF@K = \frac{1}{|U|} \sum_{u \in U} \frac{|R_u@K \cap I^{np}|}{K} \quad (16)$$

(2) 资格公平性 (Qualification Fairness, QF): 资格公平性不考虑物品被曝光次数, 只考虑是否被曝光. QF 定义为整体多样性的形式, 如式 (17) 所示:

$$QF@K = \frac{\left| \bigcup_{u \in U} R_u@K \right|}{|I|} \quad (17)$$

5.2 总体性能对比实验

为了更好地展示不同推荐算法对用户流行度偏好

的放大程度, 根据用户对流行物品的偏好程度, 本文将用户分为 3 组^[18]: (1) 最不喜欢流行物品的用户 (Niche Users, 简称 N, 前 20% 的用户); (2) 最喜欢流行物品的用户 (Blockbuster-focus Users, 简称 B, 后 20% 的用户); (3) 喜好多样化的用户 (Diversity Users, 简称 D, 其余用户).

本文首先使用 MF 作为基础模型, 比较 SSLAB 方法和对比算法的各方面表现. 为了使对比更加公平, 本文在可调整参数的 SSLAB, FairRec, xQuAD, CMIPS, CIPS 以及 ESAM 这 6 种方法结果的 Top50 中, 固定非流行物品机会公平性为数据集本身的平均长尾物品占比 (APLT) 的近似值, 使后处理方法在重排序时有充足的非流行物品. 实验结果如表 2 所示.

(1) 在 3 种不能调节推荐效果的方法 (Random-K, Poorest-K 和 Most Popular) 中, Random-K 大幅提升了推荐列表的非流行物品机会公平性 (Qualification Fairness, OF) 和资格公平性 (Qualification Fairness, QF), 但机会公平性的值却远远超过了历史记录中的 APLT, 即非流行物品的比例过高, 严重偏离了用户对非流行或流行物品的偏好程度, 且造成相关性严重降低, 使推荐失去个性化; Poorest-K 较 Random-K 更极端, 只推荐了最不流行的物品, 所以 OF 值最高, QF 值最低, 不仅没有满足物品方公平性, 而且存在更严重的用户流行度偏好不一致问题和低相关性问题; Most Popular 虽然保留了一定的相关性, 但是 $|\Delta GAP|$, QF 和 OF 都非常低, 不满足物品方公平性, 同时较高的 $|\Delta GAP|$ 说明对用户偏好放大严重, 影响用户体验.

(2) FairRec, xQuAD, CMIPS, CIPS 和 ESAM 方法虽然可以调节相关性与公平性, 但在同样的 OF 条件下, 相较于 SSLAB, 它们需要牺牲更多的相关性以满足一定的公平性. SSLAB 在 3 个数据集上都取得了更好的表现, 如在 Douban 数据集上, SSLAB 的 Recall 值为 0.040 2, 相较于 Top-K 方法, 只相对损失了 3.83%, 同时分别以 13.24%, 27.22%, 30.52%, 22.56% 和 20.36% 的相对值优于 FairRec, xQuAD, CMIPS, CIPS 和 ESAM. 大多数情况下, SSLAB 在用户体验和物品方公平性指标上都优于其他方法. SSLAB 不仅实现了较高的资格公平性, 以满足物品方的公平性需求, 同时, 对不同的用户组的 $|\Delta GAP|$ 也达到最低, 满足了用户方对流行物品和非流行物品的偏好程度.

综合以上结果, 可以看出 SSLAB 以极少的相关性为代价, 更好地满足用户体验和物品方公平性, 回答了问题 1.

5.3 可扩展性实验

为了验证本文的 SSLAB 具有较好的可扩展性, 本文选择 NGCF 和 LightGCN 作为基本模型. 实验省略了

表2 实验结果对比

Douban								
方法	Recall@10	NDCG@10	$\Delta\text{GAP}(N)@10$	$\Delta\text{GAP}(D)@10$	$\Delta\text{GAP}(B)@10$	NP@10	QF@10	OF@50
MF-BPR+Top-K	0.041 8	0.121 1	131.69%	145.81%	151.64%	9.963 7	0.055 8	0.005 6
Random-K	0.000 3	0.000 8	-87.48%	-94.16%	-92.11%	1.989 9	0.602 6	0.801 0
Poorest-K	0	0	-99.17%	-99.64%	-99.42%	0	0.000 5	1
Most Popular	0.032 7	0.099 7	573.66%	190.37%	294.74%	10.000 0	0.001 7	0
MF-BPR+FairRec	0.035 5	0.101 8	-74.11%	-69.54%	-69.08%	4.134 9	0.185 3	0.155 0
MF-BPR+xQuAD	0.031 6	0.088 6	24.12%	152.97%	147.74%	8.923 0	0.098 1	0.155 0
MF-CMIPS	0.030 8	0.082 1	53.92%	81.30%	70.96%	8.711 4	0.175 1	0.155 0
MF-CIPS	0.032 8	0.085 4	59.98%	90.77%	75.49%	8.889 2	0.151 8	0.155 0
MF-ESAM	0.033 4	0.093 1	45.24%	71.28%	62.52%	8.586 5	0.121 1	0.155 0
MF-SSLAB(本文方法)	0.040 2	0.117 3	20.26%	41.77%	37.73%	7.392 0	0.195 3	0.155 0
LastFM								
方法	Recall@10	NDCG@10	$\Delta\text{GAP}(N)@10$	$\Delta\text{GAP}(D)@10$	$\Delta\text{GAP}(B)@10$	NP@10	QF@10	OF@50
MF-BPR+Top-K	0.160 4	0.148 3	164.33%	89.91%	123.18%	9.722 0	0.102 9	0.028 0
Random-K	0.000 3	0.000 2	-80.66%	-95.74%	-92.62%	2.025 8	0.699 2	0.797 4
Poorest-K	0	0	-95.66%	-99.14%	-98.43%	0	0.001 3	1
Most Popular	0.060 1	0.062 2	1 557.07%	197.77%	431.87%	10.000 0	0.001 7	0
MF-BPR+FairRec	0.118 4	0.128 6	82.20%	53.04%	88.80%	8.463 7	0.199 5	0.217 0
MF-BPR+xQuAD	0.090 1	0.118 5	94.33%	83.46%	95.39%	8.763 4	0.126 9	0.217 0
MF-CMIPS	0.081 7	0.108 8	87.54%	76.87%	83.47%	8.637 7	0.189 1	0.217 0
MF-CIPS	0.105 1	0.129 4	90.19%	81.42%	84.66%	8.846 6	0.169 5	0.217 0
MF-ESAM	0.099 2	0.106 1	124.36%	96.58%	129.35%	9.234 9	0.106 3	0.217 0
MF-SSLAB(本文方法)	0.152 8	0.138 7	36.86%	48.12%	47.58%	7.477 6	0.209 2	0.217 0
Epinions								
方法	Recall@10	NDCG@10	$\Delta\text{GAP}(N)@10$	$\Delta\text{GAP}(D)@10$	$\Delta\text{GAP}(B)@10$	NP@10	QF@10	OF@50
MF-BPR+Top-K	0.034 2	0.019 5	86.75%	202.15%	249.61%	9.708 8	0.095 8	0.028 2
Random-K	0.000 05	0.000 03	-77.93%	-92.73%	-95.45%	1.983 1	0.846 5	0.802 0
Poorest-K	0	0	-93.53%	-97.93%	-98.69%	0	0.000 2	1
Most Popular	0.020 5	0.015 7	3 379.34%	1 003.55%	600.06%	10.000 0	0.000 2	0
MF-BPR+FairRec	0.018 3	0.012 6	83.51%	63.43%	65.76%	8.351 1	0.163 1	0.296 0
MF-BPR+xQuAD	0.019 9	0.013 9	72.03%	76.49%	83.52%	8.563 6	0.159 7	0.296 0
MF-CMIPS	0.021 4	0.016 6	68.93%	82.81%	89.19%	8.786 7	0.184 1	0.296 0
MF-CIPS	0.017 2	0.011 3	85.90%	75.14%	93.01%	8.962 7	0.175 2	0.296 0
MF-ESAM	0.022 7	0.014 4	71.54%	88.13%	74.77%	8.571 2	0.145 4	0.296 0
MF-SSLAB(本文方法)	0.031 4	0.018 2	32.88%	30.23%	42.32%	7.729 9	0.235 7	0.296 0

Random-K, Poorest-K 和 Most Popular 这 3 种表现最差的方法, 只选择了较强的 FairRec, xQuAD, CMIPS, CIPS 和 ESAM 方法作为对比. 对比情况如表 3 和表 4 所示.

(1) 尽管两种模型都达到了很高的召回率, 但它们的 $|\Delta\text{GAP}|$ 都很高, 特别是 NGCF 的 $\Delta\text{GAP}(N)$ 值高达 217.85% (MF-BPR 的 $\Delta\text{GAP}(N)$ 为 164.33%), 说明二者具有用户方的流行度偏差; 同时 OF 值都非常低, 反映推荐结果中非流行物品占比很低, 存在物品方的流行度偏差, 进一步说明了流行度偏差在推荐算法中的普遍性.

(2) 无论是 LightGCN 还是 NGCF, SSLAB 都能有效地实现更公平的推荐结果. 针对 $|\Delta\text{GAP}|$, 以 NGCF 为例, 对于不同用户组 (N, D 和 B), SSLAB 分别降低了 83.30%、44.73% 和 77.73%, 对比最好的对比方法的结果, 相对降低了 49.01%、29.22% 和 39.84%, 更好地保证了用户偏好一致性; 针对资格公平性, 提升了 134.85%, 对比最优方法结果相对提升 5.80%; 同时 SSLAB 牺牲极少的相关性, 说明 SSLAB 对更复杂的模型也可以有效保证用户和物品双方的公平性和高相关性.

(3) 通过对比表 2、表 3 和表 4 的结果可知, 模型本

表 3 NGCF 在 LastFM 数据集上的实验结果

方法	Recall@10	NDCG@10	$\Delta\text{GAP}(\text{N})@10$	$\Delta\text{GAP}(\text{D})@10$	$\Delta\text{GAP}(\text{B})@10$	NP@10	QF@10	OF@50
NGCF-BPR+Top-K	0.168 9	0.164 2	217.85%	86.52%	148.82%	9.862 8	0.098 7	0.033 6
NGCF-BPR+FairRec	0.119 5	0.131 2	89.06%	67.56%	86.87%	8.578 8	0.208 6	0.217
NGCF-BPR+xQuAD	0.108 3	0.129 0	71.37%	84.32%	64.72%	8.493 7	0.219 1	0.217
NGCF-CMIPS	0.097 2	0.113 2	78.47%	81.38%	70.91%	8.633 9	0.212 5	0.217
NGCF-CIPS	0.116 3	0.135 5	81.36%	89.71%	75.77%	8.776 3	0.204 7	0.217
NGCF-ESAM	0.102 1	0.108 6	83.24%	75.57%	55.09%	8.513 1	0.193 0	0.217
NGCF-SSLAB(本文方法)	0.157 4	0.156 7	36.39%	47.82%	33.14%	7.315 1	0.231 8	0.217

表 4 LightGCN 在 LastFM 数据集上的实验结果

方法	Recall@10	NDCG@10	$\Delta\text{GAP}(\text{N})@10$	$\Delta\text{GAP}(\text{D})@10$	$\Delta\text{GAP}(\text{B})@10$	NP@10	QF@10	OF@50
LightGCN-BPR+Top-K	0.178 1	0.175 9	96.24%	68.53%	79.61%	8.748 9	0.148 4	0.037 6
LightGCN-BPR+FairRec	0.127 1	0.153 1	86.37%	58.71%	70.74%	8.363 4	0.212 6	0.217
LightGCN-BPR+xQuAD	0.118 8	0.143 4	61.81%	66.18%	69.41%	8.113 2	0.223 5	0.217
LightGCN-CMIPS	0.109 7	0.133 6	87.54%	76.87%	83.47%	8.486 6	0.207 9	0.217
LightGCN-CIPS	0.132 4	0.146 5	90.19%	81.42%	84.66%	8.631 9	0.198 9	0.217
LightGCN-ESAM	0.121 6	0.127 5	89.21%	95.52%	84.17%	8.678 4	0.218 2	0.217
LightGCN-SSLAB(本文方法)	0.169 2	0.162 5	27.84%	35.80%	27.85%	7.191 3	0.243 6	0.217

身的性质决定了 SSLAB 优化结果的上限。具体地, LightGCN 在相关性和公平性都略优于 NGCF, 通过 SSLAB 优化后的结果可知, LightGCN 也优于 NGCF, 即效果更好的模型在使用 SSLAB 优化方法后得到的结果也会更好。

综上所述, SSLAB 在经典 MF 模型和基于图卷积的深度神经网络上都具有良好的性能, 通用性强。

5.4 参数敏感性分析



为了回答问题 3, 本文将探究调整主任务和辅助任务权重的超参数 α 对 SSLAB 性能的影响。

损失函数式(11)中包括两项任务: 第一项为主任务, 即双视图学习, 获取用户对流行物品和非流行物品各自的偏好; 第二项为辅助任务, 即自监督学习, 捕获物品间的潜在关系。通过超参数 α 权衡两项任务。


图 7~9 展示了 LastFM 数据集下, 随着 α 值的变化, recall 与 ΔGAP , QF 以及 OF 间的权衡。

(1) 随着 α 增加, recall 值呈现先增后减的趋势, 说明在 α 较小时, 辅助任务的学习有利于主任务, 但当 α 值过大时, 模型学习的重心偏向于辅助任务, 给主任务带来负面影响。对于 ΔGAP 而言, 3 个 ΔGAP 值随着 α 的增加逐渐降低, 说明辅助任务对提高用户流行度偏好一致性是有效的。

(2) 结合图 8 和图 9 可以看出, 虽机会公平性 OF 值随 α 值的增加而增加, 但在 α 值为 1.2 处的前后, 资格公平性 QF 值却呈现出先增后减的趋势, 即 α 过大时, 推荐列表中的非流行物品比例虽然一直增加, 但只是一部分非流行物品的曝光率持续提升, 资格公平性逐渐下降。所以, 要保证较高的资格公平性, α 值不宜超过

图 7 α 值对 ΔGAP 的影响图 8 α 值对 QF 的影响

1.2。结合图 7~9 的结果, 在 LastFM 下, α 的取值为 0.8。在实际应用场景中, 可以根据公平性与相关性的需求, 综合考虑图 7~9, 选择一个合适的 α 值。

图9 α 值对 OF 的影响

6 结论

本文针对推荐系统中普遍存在的流行度偏差现象,提出了基于自监督学习的去流行度偏差推荐方法(SSLAB)。该方法第一部分是分别从流行物品和非流行物品两种不同视图中捕获用户真实兴趣;第二部分采用自监督学习,构造辅助任务,充分利用交互数据,挖掘两个视图物品间的潜在关系。

在三个真实数据集上的对比实验说明 SSLAB 在基本保持推荐性能的同时,可以带来较大的物品公平性和用户体验的提升。在基于图神经网络的推荐模型 LightGCN 和 NGCF 上的实验展现了 SSLAB 良好的可扩展性。超参数 α 值的参数敏感度分析展示了选择最优 α 值的方法。下一步工作将结合基于内容的推荐更好地解决流行度偏差问题。

参考文献

- [1] ABDOLLAHPOURI H. Popularity bias in ranking and recommendation[C]//Proceedings of the 2019 AAAI/ACM Conference on AI, Ethics, and Society. Honolulu: ACM, 2019: 529-530.
- [2] VARGAS S, CASTELLS P. Improving sales diversity by recommending users to items[C]//Eighth ACM Conference on Recommender Systems. Foster City: ACM, 2014: 145-152.
- [3] MANSOURY M, ABDOLLAHPOURI H, PECHENIZKIY M, et al. Fair match: A graph-based approach for improving aggregate diversity in recommender systems[C]//Proceedings of the 28th ACM Conference on User Modeling, Adaptation and Personalization. Genoa: ACM, 2020: 154-162.
- [4] ABDOLLAHPOURI H, BURKE R, MOBASHER B. Managing popularity bias in recommender systems with personalized re-ranking[C]//Proceedings of the Thirty-Second International Florida Artificial Intelligence Research Society Conference. Sarasota: AAAI Press, 2019: 413-418.
- [5] ABDOLLAHPOURI H, BURKE R, MOBASHER B. Controlling popularity bias in learning-to-rank recommendation[C]//Proceedings of the Eleventh ACM Conference on Recommender Systems. Como: ACM, 2017: 42-46.
- [6] WANG X, HE X, WANG M, et al. Neural graph collaborative filtering[C]//Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval. Paris: ACM, 2019: 165-174.
- [7] HE X, DENG K, WANG X, et al. LightGCN: Simplifying and powering graph convolution network for recommendation[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2020: 639-648.
- [8] 陈聪, 俞东进, 吴建华, 等. 基于隐式反馈数据的个性化游戏推荐[J]. 电子学报, 2018, 46(11): 2626-2632.
CHEN C, YU D J, WU J H, et al. Personalized game recommendation based on implicit feedback[J]. Acta Electronica Sinica, 2018, 46(11): 2626-2632. (in Chinese)
- [9] 郭景峰, 朱晓松, 李爽. 直播电视推荐系统的评分预测算法研究[J]. 电子学报, 2020, 48(9): 1735-1740.
GUO J F, ZHU X S, LI S. Research on rating algorithm of live TV recommender systems[J]. Acta Electronica Sinica, 2020, 48(9): 1735-1740. (in Chinese)
- [10] RENDLE S, FREUDENTHALER C, GANTNER Z, et al. BPR: Bayesian personalized ranking from implicit feedback[C]//Proceedings of the Twenty-Fifth Conference on Uncertainty in Artificial Intelligence. Montreal: AUAI Press, 2009: 452-461.
- [11] HJELM R, FEDOROV A, LAVOIE-MARCHILDON S, et al. Learning deep representations by mutual information estimation and maximization[C]//7th International Conference on Learning Representations. New Orleans: OpenReview, 2019: 233-256.
- [12] KONG L, D' AUTUME C, YU L, et al. A mutual information maximization perspective of language representation learning[C]//8th International Conference on Learning Representations. Addis Ababa: OpenReview, 2020: 1167-1178.
- [13] LINSKER R. Self-organization in a perceptual network[J]. IEEE Computer, 1988, 21(3): 105-117.
- [14] CARSE J, CAREY F, MCKENNA S. Unsupervised representation learning from pathology images with multi-directional contrastive predictive coding[C]//18th IEEE International Symposium on Biomedical Imaging. Nice: IEEE, 2021: 1254-1258.
- [15] ZHOU K, WANG H, ZHAO W, et al. S3-Rec: Self-supervised learning for sequential recommendation with mutu-

- al information maximization[C]//The 29th ACM International Conference on Information and Knowledge Management. Ireland: ACM, 2020: 1893-1902.
- [16] MA J, ZHOU C, YANG H, et al. Disentangled self-supervision in sequential recommenders[C]//The 26th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. CA: ACM, 2020: 483-491.
- [17] PARK Y J, TUZILIN A. The long tail of recommender systems and how to leverage it[C]//Proceedings of the 2008 ACM Conference on Recommender Systems. Lausanne: ACM, 2008: 11-18.
- [18] ABDOLLAHPOURI H, MANSOURY M, BURKE R, et al. The unfairness of popularity bias in recommendation [C]//Proceedings of the Workshop on Recommendation in Multi-Stakeholder Environments Co-Located with the 13th ACM Conference on Recommender Systems, Copenhagen: CEUR-WS, 2019: 1257-1263.
- [19] PATRO G, BISWAS A, GANGULY N, et al. FairRec: Two-sided fairness for personalized recommendations in two-sided platforms[C]//Proceedings of The Web Conference 2020. Taipei: ACM, 2020: 1194-1204.
- [20] VARDASBI A, RIJKE M, MARKOV I. Cascade model-based propensity estimation for counterfactual learning to rank[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2020: 2089-2092.
- [21] SAITO Y, YAGINUMA S, NISHINO Y, et al. Unbiased recommender learning from missing-not-at-random implicit feedback[C]//The Thirteenth ACM International Conference on Web Search and Data Mining. Houston: ACM, 2020: 501-509.
- [22] SINHA A, GLEICH D, RAMANI K. Deconvolving feedback loops in recommender systems[C]//Advances in Neural Information Processing Systems 29: Annual Conference on Neural Information Processing Systems. Barcelona: ACM, 2017: 3243-3251.
- [23] ZHENG Y, GAO C, LI X, et al. Disentangling user interest and conformity for recommendation with causal conference embedding[C]//Proceedings of The Web 2021. Ljubljana: ACM, 2021: 2980-2991.
- [24] DEVLINJ, CHANGM, LEEK, et al. BERT: Pre-training of deepbi directional transformers for language[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language. Minneapolis: ACL, 2019: 4171-4186.
- [25] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems. Long Beach: ACM, 2017: 5998-6008.
- [26] CHEN Z, XIAO R, LI C, et al. ESAM: Discriminative domain adaptation with non-displayed items to improve long-tail performance[C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development In Information Retrieval. New York: ACM, 2020: 579-588.

作者简介



张 帅 男,1997年生. 现为重庆大学大数据与软件学院在读硕士研究生. 主要研究方向为机器学习、推荐系统等.

E-mail: zhangshuai@cqu.edu.cn



高 旻(通讯作者) 女,1980年生. 工学博士. 重庆大学大数据与软件学院副教授、硕士生导师. 主要研究方向为推荐系统、异常检测、社交媒体挖掘.

E-mail: gaomin@cqu.edu.cn



文俊浩 男,1969年生. 工学博士. 重庆大学软件学院教授. 主要研究方向为计算智能与推荐系统.

E-mail: jhwen@cqu.edu.cn



熊庆宇 男,1965年生. 工学博士. 重庆大学大数据与软件学院教授、博士生导师. 主要研究方向为智能控制、传感器网络和信息系統.

E-mail: xiong03@cqu.edu.cn



唐 旭 男,1983年生. 现为重庆大学机械学院在读博士研究生. 主要研究方向为智能制造与推荐系统.

E-mail: tangxu@cqu.edu.cn